Do simbólico à incerteza: infraestrutura digital básica nas escolas do Amazonas

Camila dos Santos Soares, Daniel Nunes Santos, José Eduardo,
Nicoly Lima de Souza, Pedro Matheus Melo Pereira e Pedro Vinícius Díaz de Alencar

Fundamentos de Inteligência Artificial — Prof. Edjard Mota

Novembro de 2026

Resumo

Este trabalho aplica seis abordagens de Inteligência Artificial a dados do Censo Escolar 2025, com recorte para escolas do Amazonas. A classificação identifica infraestrutura digital básica e a regressão estima equipamentos para alunos por sala. Implementamos árvore de decisão, regressões, cálculos de probabilidade, Naive Bayes, Expectation-Maximization (EM), rede Bayesiana e lógica fuzzy. A árvore atingiu 87,65% de acurácia média em cinco folds. O Naive Bayes obteve 84,42%, e a inclusão de um perfil obtido por EM reduziu o resultado para 83,34% em uma divisão 70/30. A enumeração coincidiu com a eliminação de variáveis do pgmpy. O sistema fuzzy recebe as probabilidades da rede e fornece urgência de apoio interpretável. Discutimos desbalanceamento, limitações do DAG e diferenças entre interpretar decisões e melhorar a previsão.

Palavras-chave: Censo Escolar; árvore de decisão; redes Bayesianas; EM; lógica fuzzy.

1 Problema, dados e preparação

A pergunta principal é: *a escola tem infraestrutura digital básica?* Adotamos um critério operacional, sem pretender avaliar toda a qualidade da escola. A classe $Y = 1$ exige internet para alunos e pelo menos um tipo de equipamento para eles: desktop, computador portátil ou tablet. A internet informada não deve ser interpretada especificamente como conexão Wi-Fi. As demais escolas recebem $Y = 0$.

A fonte registrada pela equipe é o arquivo `Tabela_Escola_2025_V2.csv`, do INEP, com acesso em 29/10/2026 [4]. Filtramos Amazonas e situação de funcionamento igual a 1. A base de classificação contém 5.562 escolas: 4.555 da classe 0 (81,90%) e 1.007 da classe 1 (18,10%). O identificador `CO_ENTIDADE` não participa do aprendizado. As colunas que definem o alvo também não entram como preditoras da classificação.

Símbolo	Coluna	Significado/códigos
L	`IN_LABORATORIO_INFORMATICA`	Laboratório, 0/1
B	`IN_BIBLIOTECA`	Biblioteca, 0/1
LOC	`TP_LOCALIZACAO`	1 urbana; 2 rural
DEP	`TP_DEPENDENCIA`	1 federal; 2 estadual; 3 municipal; 4 privada
G	`IN_ENERGIA_GERADOR_FOSSIL`	Gerador a combustível fóssil, 0/1

O gerador da primeira base remove ausentes nas pistas e trata ausentes nas colunas do alvo como zero. Essa última decisão exige cuidado: não informado não significa necessariamente inexistente. O registro de execução fornecido pela equipe informa ausência de vazios no recorte utilizado; os CSVs finais também não têm ausentes. A fonte bruta e o dicionário devem ser preservados pela equipe para rastreabilidade.

A segunda base tem 5.526 escolas e alvo contínuo

$$D = \frac{\text{QT_DESKTOP_ALUNO} + \text{QT_COMP_PORTATIL_ALUNO} + \text{QT_TABLET_ALUNO}}{\text{QT_SALAS_UTILIZADAS}}.$$

Seu gerador trata o código 88888 como ausente nas quantidades usadas, remove ausentes e restringe escolas a até 60 salas. Esse limite é uma escolha de limpeza, não uma regra do domínio. Os arquivos tratados permitem executar os notebooks sem baixar o microdado nacional. O escopo implementado usa dados do INEP, sem junção com IBGE.

2 Etapa 1: árvore, entropia e limites da lógica

Implementamos LEARN-DECISION-TREE, com divisões por valores categóricos e escolha do maior ganho de informação [1]. Folhas puras retornam a classe; sem atributos ou ao atingir a profundidade máxima, usamos a maioria. Um valor não observado no treino recebe a classe majoritária do nó. Comparamos a implementação com *DecisionTreeClassifier*, usando codificação one-hot para o sklearn.

2.1 Cálculos dos três primeiros níveis

Contamos a raiz como nível 1, seus filhos como nível 2 e os netos como nível 3. Para duas classes, definimos $h(p) = -p\log_2 p - (1-p)\log_2(1-p)$, com $h(0) = h(1) = 0$. Assim,

$$H(S) = h\Big(\frac{n_1}{N}\Big), \qquad GI(S,A) = H(S) - \sum_v \frac{N_v}{N} h\Big(\frac{n_{1,v}}{N_v}\Big).$$

Na raiz, $H = h(1007/5562) = 0,68237$ bit. O laboratório separa 4.607 escolas (369 positivas) de 955 (638 positivas). A entropia ponderada é $0,49084$; portanto, $GI = 0,68237 - 0,49084 = 0,19153$. A tabela apresenta as frações de cada ramo. Os ganhos dos outros candidatos na raiz são: biblioteca 0,09893; localização 0,09528; dependência 0,04378; gerador 0,00878. Portanto, laboratório é escolhido. A tabela mostra as substituições numéricas de cada divisão dos três níveis. Subtrai-se a quarta coluna da terceira para obter a última.

Condição do nó	Atributo	Entropia do nó	Entropia ponderada dos filhos	Ganho
Raiz	L	$h(1007/5562)$	$\frac{4607h\left(\frac{369}{4607}\right)+955h\left(\frac{638}{955}\right)}{5562}$	0.19153
L=0	LOC	$h(369/4607)$	$\frac{1107h\left(\frac{181}{1107}\right)+3500h\left(\frac{188}{3500}\right)}{4607}$	0.01869
L=0, LOC=1	DEP	$h(181/1107)$	$\frac{2h\left(\frac{1}{2}\right)+220h\left(\frac{41}{220}\right)+608h\left(\frac{76}{608}\right)+277h\left(\frac{63}{277}\right)}{1107}$	0.01084
L=0, LOC=2	DEP	$h(188/3500)$	$\frac{137h\left(\frac{2}{137}\right)+3360h\left(\frac{185}{3360}\right)+3h\left(\frac{1}{3}\right)}{3500}$	0.00167
L=1	DEP	$h(638/955)$	$\frac{17h\left(\frac{17}{17}\right)+401h\left(\frac{212}{401}\right)+413h\left(\frac{314}{413}\right)+124h\left(\frac{95}{124}\right)}{955}$	0.05249
L=1, DEP=2	G	$h(212/401)$	$\frac{400h\left(\frac{212}{400}\right)+1h\left(\frac{0}{1}\right)}{401}$	0.00271
L=1, DEP=3	LOC	$h(314/413)$	$\frac{285h\left(\frac{235}{285}\right)+128h\left(\frac{79}{128}\right)}{413}$	0.03468
L=1, DEP=4	G	$h(95/124)$	$\frac{116h\left(\frac{87}{116}\right)+8h\left(\frac{8}{8}\right)}{124}$	0.02576

O ramo $L = 1$, DEP=1 contém 17 escolas, todas positivas; sua entropia é zero e não requer nova divisão. Ramos sem exemplos não contribuem para a soma ponderada. As expressões permitem refazer os cálculos com calculadora; o histórico da implementação foi usado para conferir contagens e resultados.

2.2 Validação e monotonicidade

Com profundidade 3, a validação estratificada 5-fold obteve $87,65\% \pm 0,32$ ponto percentual para a árvore própria e 87,67% para o sklearn com entropia. Prever sempre a maioria alcança 81,90%. A árvore sem limite obteve 87,52%, sem vantagem observada. O ID3 tem divisões multirramos, enquanto o sklearn usa divisões binárias; profundidades iguais não garantem estruturas equivalentes.

Na lógica clássica, monotonicidade significa que acrescentar premissas a uma base não retira consequências que já eram deriváveis. A aprendizagem por exemplos funciona de outra maneira: o modelo é uma hipótese estimada a partir de uma amostra e pode ser revisto quando chegam observações novas. Uma previsão da árvore não é uma verdade universal demonstrada sobre todas as escolas.

Por exemplo, considere uma folha com duas escolas da classe 0 e uma da classe 1. A maioria leva à previsão 0. Se incluirmos duas novas escolas da classe 1 com as mesmas pistas e treinarmos novamente, a folha passa a ter duas negativas e três positivas. Sua previsão muda para 1, inclusive para uma escola que anteriormente recebia 0. Novos exemplos também podem alterar os ganhos de informação e a estrutura dos ramos.

Isso não contradiz a monotonicidade da dedução clássica: são operações diferentes. A dedução preserva consequências das premissas; a indução modifica a hipótese para acomodar a evidência disponível. Uma regra universal como "toda escola com laboratório tem infraestrutura digital básica" também é inadequada: há 317 contraexemplos entre as 955 escolas com laboratório. A árvore produz uma decisão baseada em frequências, sujeita a erro e revisão. Por isso avaliamos escolas fora do treino e tratamos as regras como padrões dos dados, não como garantias.

3 Etapa 2: aprendizado linear

Para prever D, usamos internet para alunos, laboratório, internet para aprendizagem, quantidade de TVs, quantidade de equipamentos multimídia e lousa digital. São informações de infraestrutura; não incluímos diretamente as quantidades de aparelhos que compõem o numerador do alvo.

Na regressão univariada, calculamos a reta pela fórmula fechada:

$$\hat{D} = \theta_0 + \theta_1 x, \quad \theta_1 = \frac{\sum_i (x_i - \bar{x})(D_i - \bar{D})}{\sum_i (x_i - \bar{x})^2}, \quad \theta_0 = \bar{D} - \theta_1 \bar{x}.$$

A preditora padrão é internet para alunos, definida antes de avaliar o teste pela associação interpretável entre conectividade e disponibilidade de equipamentos. A reta obtida é $\hat{D} = 0,2776 + 2,2107x$, com $R^2 = 0,2372$ no teste. A avaliação não seleciona a variável. Essa correção substitui o procedimento anterior, que destacava o maior resultado entre variáveis usando o próprio teste.

Na multivariada, minimizamos $J(\theta) = \|X\theta - D\|^2/(2m)$ por $\theta \leftarrow \theta - \alpha X^T(X\theta - D)/m$. Adicionamos uma coluna de 1 para o intercepto e padronizamos preditoras com média e desvio do treino. Com $\alpha = 0,1$, a execução convergiu em 163 iterações. A comparação com *LinearRegression* usou as mesmas escolas e produziu o mesmo R^2 arredondado.

No Ridge, acrescentamos $\lambda \sum_{j \geq 1} \theta_j^2/(2m)$ ao custo, sem penalizar o intercepto. A escolha de λ foi feita por cinco folds somente no treino. O valor selecionado foi aproximadamente 77,43. O gradiente regularizado foi conferido contra a solução fechada; a diferença máxima nos coeficientes ficou abaixo de 6×10^{-7} nos valores testados. A penalização controla a magnitude global dos coeficientes; não exige que cada coeficiente individual diminua monotonicamente em todo trecho do caminho.

Modelo	R^2 teste	MSE teste
Univariada (internet para alunos)	0,2372	2,0311
Multivariada por gradiente	0,3228	1,8030
Ridge, λ escolhido por CV	0,3237	1,8006

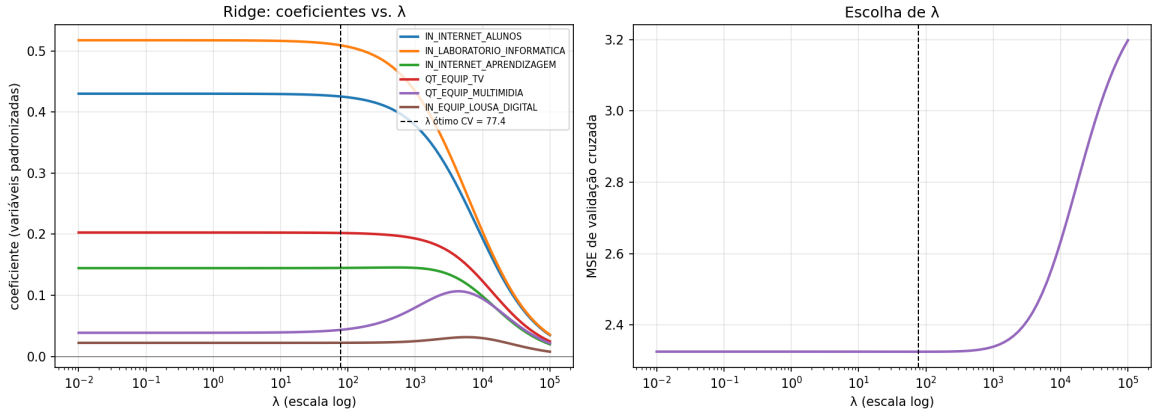


Figura 1: caminho dos coeficientes e escolha de λ por validação no treino.

A logística retorna ao alvo binário da Etapa 1. Implementamos sigmoide, entropia cruzada e gradiente, com $P(Y = 1 \mid x) = 1/(1 + e^{-x^T\theta})$. Dependência administrativa usa variáveis indicadoras; o identificador é excluído. A comparação com *LogisticRegression*, praticamente sem regularização, apresentou diferença máxima de coeficientes de cerca de 0,0018.

Em uma divisão estratificada 80/20, com limiar 0,5, a logística obteve 88,40% de acurácia, precisão 76,87%, recall 51,24%, F1 61,49% e AUC 0,8358. A matriz de confusão foi $\left[\begin{smallmatrix} 880 & 31 \\ 98 & 103 \end{smallmatrix}\right]$. Assim, quase metade das escolas positivas não foi identificada. O baixo R^2 das regressões e o recall limitado da logística mostram que essas pistas não resumem todos os fatores de informatização. O pequeno ganho de Ridge deve ser apresentado sem exagero.

4 Etapa 3: probabilidade

O experimento é escolher uma escola uniformemente entre as 5.562 linhas. Os eventos são definidos pelas características observadas. Satisfazemos não negatividade, $P(\Omega) = 1$ e aditividade para eventos disjuntos. As quatro combinações de laboratório e biblioteca são disjuntas e cobrem a base:

Evento (L, B)	Contagem	Probabilidade
$(0, 0)$	3994	0,71809
$(0, 1)$	613	0,11021
$(1, 0)$	213	0,03830
$(1, 1)$	742	0,13341

As probabilidades somam 1 antes de arredondar. Temos $P(L = 1) = 955/5562 = 0,17170$ e $P(B = 1) = 1355/5562 = 0,24362$. As condicionais usam denominadores distintos: $P(B = 1 \mid L = 1) = 742/955 = 77,70\%$ e $P(L = 1 \mid B = 1) = 742/1355 = 54,76\%$.

A regra da cadeia para três variáveis é verificada por

$$P(Y = 1, L = 1, B = 1) = \frac{1007}{5562}\frac{638}{1007}\frac{496}{638} = \frac{496}{5562} = 8,9177\%.$$

Por Bayes, $P(Y = 1 \mid L = 1) = P(L = 1 \mid Y = 1)P(Y = 1)/P(L = 1) = 638/955 = 66,81\%$. Trata-se de uma inferência diagnóstica a partir da pista; não mede o efeito causal de instalar um laboratório. Para $Y = 0$, $P(L = 1, B = 1 \mid Y) = 5,40\%$, mas o produto das marginais condicionais é 1,14%. Para $Y = 1$, os valores são 49,26% e 38,32%. Logo, não há independência condicional exata na distribuição empírica.

Na lógica de primeira ordem clássica, a afirmação sobre uma escola é verdadeira ou falsa em uma interpretação. Uma chance de 70% exige uma distribuição, que não é expressa apenas pelo valor de verdade de um predicado. A probabilidade permite representar frequências e incerteza, em vez de assumir uma regra universal sem exceções.

5 Etapa 4: aprendizado probabilístico e EM

Dividimos a base em 70% de treino e 30% de teste, com `random_state=42`. Essa divisão não é estratificada. Entre 3.893 escolas de treino, 725 são positivas. Para uma Bernoulli, $\hat{\theta}_{MLE} = s/n = 0,1862$. Com prior Beta$(2, 2)$, o máximo a posteriori é

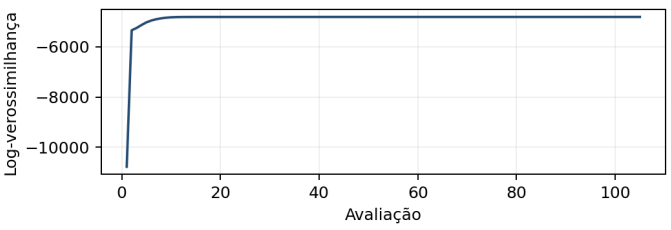
$$\hat{\theta}_{MAP} = \frac{s + 2 - 1}{n + 2 + 2 - 2} = \frac{726}{3895} = 0,1864.$$

O Naive Bayes próprio estima $P(Y)$ e $P(X_j \mid Y)$ por contagens com suavização de Laplace. Na previsão, soma logaritmos para evitar produtos muito pequenos. A independência condicional é uma aproximação, já contrariada por laboratório e biblioteca na etapa anterior.

Para inferir uma variável oculta $Z \in \{0, 1\}$, ajustamos uma mistura de Bernoulli sobre laboratório, biblioteca e gerador, apenas no treino. No passo E, calculamos responsabilidades $r_{ik} = P(Z = k \mid x_i)$. No passo M, atualizamos $\pi_k = \sum_i r_{ik}/n$ e $p_{kj} = \sum_i r_{ik}x_{ij}/\sum_i r_{ik}$. Monitoramos $\ell = \sum_i \log \sum_k \pi_k P(x_i \mid Z = k)$ e paramos quando a mudança média por escola fica abaixo de 10^{-7}, com limite de 500 avaliações.

A curva cresceu até a avaliação 105. Um perfil, de peso 0,294, apresentou probabilidades de 0,596 para laboratório, 0,777 para biblioteca e 0,030 para gerador. O outro, de peso 0,706, apresentou aproximadamente 0,000, 0,025 e 0,162; o zero exibido é arredondamento. O gráfico está no notebook da etapa.

No mesmo teste de 1.669 escolas, NB puro obteve 84,42% e NB com o perfil mais provável do EM obteve 83,34%. O perfil resume pistas já utilizadas; sua inclusão pode reforçar informação dependente. Maior verossimilhança da mistura não garante melhor classificação. Mantemos a piora observada e não interpretamos perfis como categorias oficiais de escolas.



Log-verossimilhança da mistura Bernoulli no treino.

6 Etapa 5: redes Bayesianas

Modelamos seis variáveis por um DAG. As arestas indicam dependências plausíveis, sem comprovação causal: LOC→DEP descreve a distribuição das redes por localização; LOC→ G relaciona localização e uso de gerador; DEP→ L e DEP→ B representam diferenças de investimento; $G \to L$ e $G \to Y$ representam associação com a disponibilidade de energia; $L \to Y$ e $B \to Y$ associam infraestrutura física ao alvo.

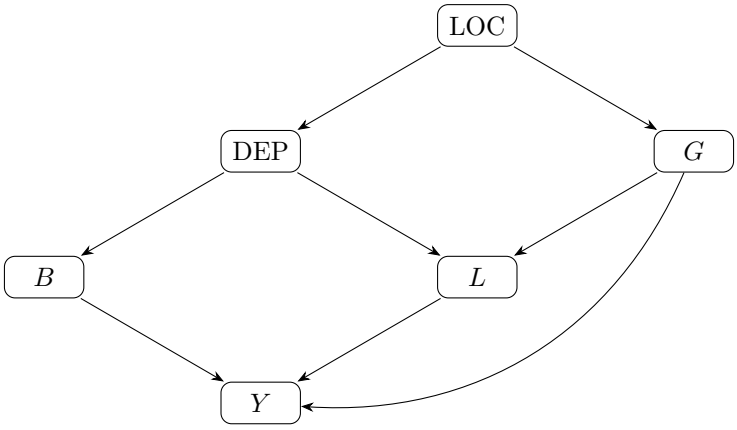


Figura 2: DAG efetivamente implementado na versão analisada.

As tabelas condicionais (CPTs) são estimadas por $P(X = x \mid c) = [N(x, c) + 1]/[N(c) + |X|]$. Isso evita zeros em combinações raras. A enumeração própria soma o produto das CPTs sobre variáveis ocultas e normaliza. Conferimos 76 consultas contra a marginalização da conjunta, cuja soma é 1; a maior diferença foi $2,2 \times 10^{-16}$.

Também comparamos com *VariableElimination* do pgmpy: primeiro com as mesmas CPTs, depois com CPTs estimadas pela biblioteca usando prior K2. Na execução de verificação, a diferença máxima das consultas foi $1,11 \times 10^{-16}$, e a diferença das CPTs foi zero. Essa concordância valida a inferência para o modelo, não a fidelidade do modelo ao mundo real.

Consulta	Rede	Frequência empírica
$P(Y = 1)$	0,1890	0,1810
$P(Y = 1 \mid LOC = 2)$	0,1484	0,0780
$P(Y = 1 \mid L = 1)$	0,6643	0,6681
$P(LOC = 2 \mid Y = 1)$	0,5175	0,2840

6.1 d-separação e colisor

No grafo, $B \perp L \mid DEP$: observar DEP bloqueia as bifurcações relevantes, enquanto os caminhos por Y contêm colisor não observado. Ao observar também Y, o caminho $B \to Y \leftarrow L$ abre. A segunda independência é $DEP \perp G \mid LOC$; observar o colisor L abre $DEP \to L \leftarrow G$. Conferimos bloqueios por caminhos e por moralização do grafo ancestral.

Um exemplo numérico fixa DEP=3. Sem observar Y, a rede dá $P(L = 1) = 0,0947$ tanto com $B = 0$ quanto com $B = 1$. Observando $Y = 1$, os valores mudam de aproximadamente 0,52 para 0,26: a biblioteca ajuda a explicar o resultado e reduz a probabilidade de laboratório no modelo. Nos dados, biblioteca e laboratório continuam associados positivamente; o exemplo demonstra o mecanismo do grafo, não um efeito causal constatado.

Os testes empíricos rejeitam as duas independências, com efeitos diferentes: informação mútua condicional de aproximadamente 0,119 bit para biblioteca/laboratório e 0,010 bit para dependência/gerador. Estratos pequenos limitam o qui-quadrado. A falta de LOC→ Y ajuda a explicar o erro nas consultas rurais. Avaliar essa aresta e $B \to L$ é uma melhoria futura, que exige nova validação.

6.2 Economia de parâmetros

A conjunta precisa de $2 \cdot 4 \cdot 2 \cdot 2 \cdot 2 \cdot 2 - 1 = 127$ parâmetros livres. A rede precisa de $1 + 6 + 2 + 4 + 8 + 8 = 29$, considerando cada nó e as configurações dos pais: economia de 98, ou 77,2%. As duas arestas propostas elevariam o total para 45. A economia reduz complexidade, mas introduz viés quando as independências assumidas não representam bem os dados.

7 Etapa 6: lógica fuzzy e integração

O sistema Mamdani usa *scikit-fuzzy*. A primeira entrada é risco $r = P(Y = 0 \mid e)$, calculado pela enumeração da Etapa 5. A segunda é suporte amostral, denominado confiança: $c = \min(N_e, 100)$, em que N_e conta escolas do treino com a mesma evidência. A saída é urgência de apoio, de 0 a 100. Essa confiança é uma heurística, não um intervalo estatístico nem garantia de acerto.

Os vértices das funções de pertinência triangulares são apresentados abaixo, separados por ponto e vírgula:

Variável	Baixo/baixa	Médio/média	Alto/alta
Risco	$[0; 0; 0, 5]$	$[0, 25; 0, 5; 0, 75]$	$[0, 5; 1; 1]$
Confiança	$[0; 0; 100]$	—	$[0; 100; 100]$
Urgência	$[0; 0; 50]$	$[25; 50; 75]$	$[50; 100; 100]$

Os conjuntos cobrem os universos; suas pertinências não precisam somar 1 e, no risco e na urgência, essa soma varia de 0,5 a 1. As três regras são:

1. Se risco é alto **e** confiança é alta, então urgência é alta.
2. Se risco é médio **ou** confiança é baixa, então urgência é média.
3. Se risco é baixo, então urgência é baixa.

Usamos mínimo para E, máximo para OU e agregação, e centroide para defuzzificação [2, 3]. A saída recebe o termo com maior pertinência. Por exemplo, escolas urbanas estaduais sem gerador têm $N = 586$ e $P(Y = 1) = 0,426$ na rede ajustada à base completa. O risco 0,574 ativa a regra média em aproximadamente 0,703 e a alta em 0,149, resultando em urgência 55,45, de rótulo médio.

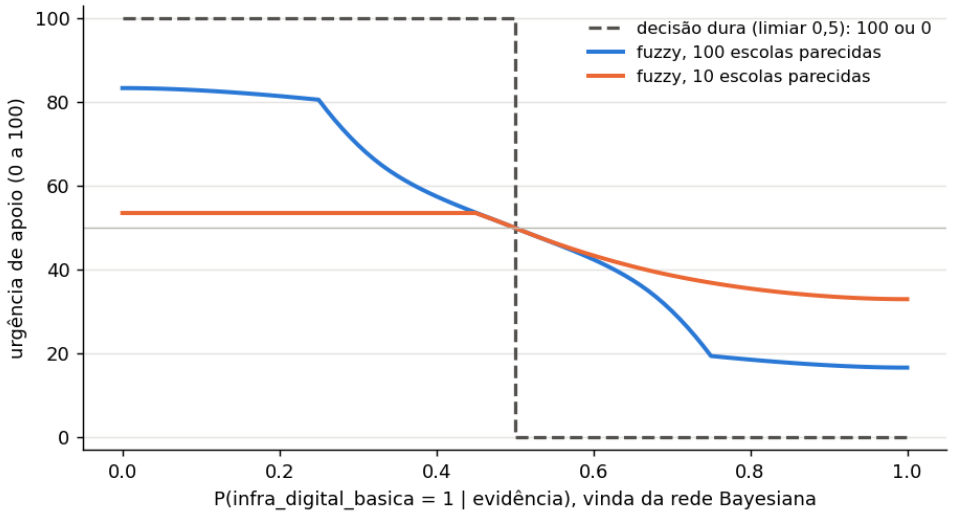


Figura 3: decisão dura e urgência fuzzy, variando a probabilidade e o suporte.

Na avaliação 5-fold estratificada, CPTs e contagens vêm somente do treino. Com evidência LOC, DEP e G, fuzzy e limiar duro concordaram em 100% das escolas, com acurácia 82,29% e recall positivo de apenas 2,28%. A AUC para falta de infraestrutura foi 0,511 na decisão dura, 0,666 na probabilidade da rede e 0,656 na urgência. Portanto, o fuzzy preserva parte da ordenação perdida pelo limiar e oferece rótulos, mas não supera a probabilidade original em discriminação.

Com evidência G, L, B, a acurácia foi 87,67% para as duas decisões; a AUC da rede foi 0,816 e a fuzzy, 0,815. O aumento depende da evidência adicional, não apenas do fuzzy. Os triângulos e o limite de 100 escolas foram escolhas da equipe. Urgência 83 não significa 83% de chance. O centroide produz, neste sistema, extremos próximos de 17 e 83. A falta de dados puxa a decisão para o meio; um gestor ainda precisa validar as regras e as prioridades.

8 Integração, discussão e reprodução

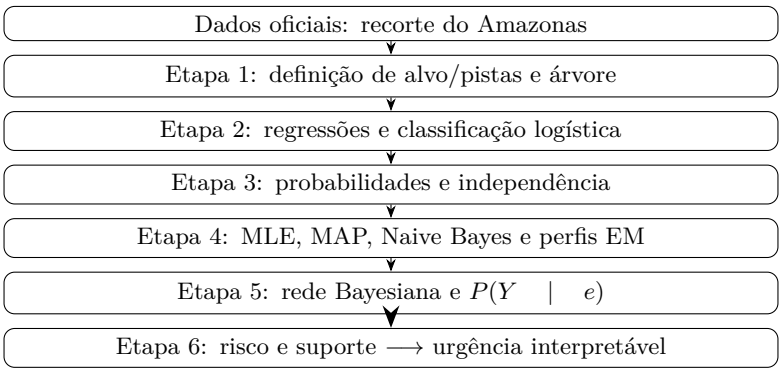


Figura 4: sequência metodológica (tracejada) e transferência de probabilidades 5–6 (contínua). A integração adicional 1/4–6 é descrita no texto.

O CSV, o alvo e as pistas da Etapa 1 são reaproveitados nas Etapas 3–6. A integração operacional implementada é 5→6: `fuzzy.py` importa a enumeração e calcula suas entradas. O uso de suavização também relaciona as etapas probabilísticas: em uma linha Bernoulli, Laplace coincide com o MAP Beta$(2, 2)$; para mais categorias, a formulação correspondente usa Dirichlet.

Integração operacional adicional. O script `integracao.py` usa todas as cinco pistas em uma divisão estratificada 70/30. Árvore, NB e CPTs são ajustados apenas no treino. A probabilidade do NB modula a confiança fuzzy por $\min(N_e, 100)(1 - |P_{NB} - P_{rede}|)$. A decisão da árvore encaminha a ação final para revisão quando diverge da classe da rede. Essa regra é uma heurística explícita, não confiança estatística. A demonstração não substitui os resultados anteriores em cinco folds nem comprova ganho de acurácia.

Os resultados mostram diferentes compromissos. A árvore gera regras simples; a regressão quantifica associações, com poder explicativo limitado; o NB simplifica dependências e o EM identifica perfis, sem ganho de acurácia observado. A rede representa dependências explicitamente e permite consultas, mas seu DAG produz viés. O fuzzy organiza uma decisão legível e suave, sem corrigir erros das probabilidades de entrada.

As métricas não formam um ranking único: árvore e fuzzy usam cinco folds, NB usa 70/30 e logística usa 80/20; algumas comparações também mudam as evidências. Uma comparação conclusiva entre algoritmos requer mesmas partições e mesmas informações disponíveis. O desbalanceamento exige considerar recall e F1, além de acurácia. Também não extrapolamos automaticamente os resultados do Amazonas para outros estados ou anos.

8.1 Reprodução e versão dos resultados

Este artigo documenta a revisão de 07/11/2026, baseada no commit `2a7676f`, com seleção univariada corrigida, do repositório da equipe[1]. Instalam-se as dependências de `requirements.txt`, seleciona-se o ambiente Python no VS Code e executam-se `etapa1.ipynb` a `etapa6.ipynb`, a partir da raiz. As divisões usam sementes fixas; há também semente 0 no sklearn e na CV interna do Ridge, além de 42 nas principais divisões.

A execução de verificação percorreu as células em processos Python separados, com Python 3.12, NumPy 2.3.5, pandas 2.2.3, scikit-learn 1.8.0, pgmpy 1.1.2 e scikit-fuzzy 0.5.0. As seis etapas concluíram sem exceções. Essa verificação não substitui a execução e gravação dos notebooks no ambiente da equipe. Alterações posteriores de dados, modelos ou divisão exigem atualizar números, gráficos e conclusões deste artigo.

Referências

[1] RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. Pearson, 2020.

[2] ZADEH, L. A. Fuzzy sets. *Information and Control*, v. 8, n. 3, p. 338–353, 1965.

[3] HÜLLERMEIER, E. Fuzzy machine learning and data mining. *WIREs Data Mining and Knowledge Discovery*, v. 1, n. 4, p. 269–283, 2011.

[4] INEP. *Censo Escolar 2025: Tabela Escola, versão V2*. Portal de dados abertos: `https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos`. Acesso registrado pela equipe: 29 out. 2026.

[1] `https://github.com/pwtheus/pipeline-ia-simbolico-incerteza`

A Uso de IA e registro de prompts

Utilizamos assistentes de IA como apoio à organização, geração/revisão de código e explicação dos métodos. Os registros abaixo são uma seleção, não um histórico integral. **Fornecido** indica mensagem ou síntese enviada por integrantes; **reconstruído** indica uma formulação representativa preparada posteriormente para documentar o tipo de apoio, sem afirmar que foi digitada literalmente. Os registros da Etapa 1 informam uso do Claude. Este artigo e sua revisão também tiveram apoio do ChatGPT.

A.1 Registros fornecidos: definição do problema e Etapa 1

1. **Pergunta e plano.** "O domínio é educação, me dê sugestões que podemos buscar responder, porque através da pergunta podemos definir os atributos. Eu vou mandar a planilha com todas as colunas." Depois: "Objetivo agora é fazer a primeira etapa." O apoio organizou as tarefas e sugeriu perguntas; a disponibilidade de colunas levou à escolha de infraestrutura.
2. **Alvo e pistas.** "A escola se adequa a padrões modernos de informatização? Variáveis: laboratório de informática, biblioteca, localização, tipo de dependência, gerador de energia elétrica." O diálogo refinou a pergunta para infraestrutura digital básica e distinguiu pistas, alvo e identificador. Foram consultadas imagens do dicionário para conferir códigos.
3. **Definição operacional.** "Para a Etapa 1 pode ser 'a escola tem infraestrutura digital básica?', considerando que sim se tiver wifi e pelo menos um aparelho para os alunos." O resultado foi ajustado para internet para alunos, sem afirmar que é Wi-Fi, e pelo menos um indicador de aparelho. O script gerou o CSV; o registro da equipe informa 5.562 linhas e distribuição 4.555/1.007.
4. **Cálculo e revisão.** "Por que estamos fazendo isso? O que essa tabela cruzada traz para a Etapa 1?"; "Qual é a fórmula que a pessoa precisa saber?"; "Meu amigo mandou isso, é coerente com o que você está fazendo?" Também foi enviado o código da árvore para revisão. Foram explicados entropia e ganho, conferidos números e relacionada a implementação ao pseudocódigo.

A.2 Registros fornecidos: Etapas 2 e 5

Etapa 2. "Estou fazendo um trabalho sobre Aprendizagem de Máquina, mais especificamente sobre Aprendizado Linear. Tenho de filtrar uma base de dados, escolhendo uma variável-alvo e variáveis preditivas. O tema é informatização da escola." Em seguida foi solicitada uma razão entre variáveis e escolhida a soma de desktops, portáteis e tablets dividida pelas salas utilizadas. O pedido final solicitou CSV e gerador, recorte Amazonas, tratamento dos problemas identificados e as seis preditoras descritas na Seção 3. O apoio resultou na preparação da base; os modelos foram conferidos com soluções fechadas e scikit-learn.

Etapa 5. "Modelar dependências entre 4–6 variáveis do domínio usando uma rede Bayesiana, e usar inferência para responder consultas. Como devo preparar os dados para realizar as tarefas dessa parte? Posso utilizar os dados que utilizei na etapa 1 ou na etapa 2?" Depois de fornecer a definição de `infra_digital_basica`, foi pedido: "Ajuste as arestas, se necessário, e desenhe o DAG." Outro pedido solicitou conferir economia de parâmetros, concordância com pgmpy e demonstração de colisor. O resultado foi confrontado com CPTs, enumeração, d-separação e contagem de parâmetros.

A.3 Prompts complementares reconstruídos

1. **Validação e lógica:** "Compare nossa árvore com o scikit-learn nas mesmas divisões, faça 5-fold estratificado e explique, com um exemplo simples, como novos dados podem alterar uma previsão. Não use apenas acurácia de treino."
2. **Regressões:** "Implemente fórmula fechada, gradiente descendente, Ridge e logística de forma simples. Padronize usando apenas o treino, escolha lambda por validação interna e compare com scikit-learn."
3. **Probabilidade:** "Use laboratório, biblioteca e a classe para calcular conjunta, marginais, condicionais, cadeia e Bayes. Confira as contagens e discuta independência e diferença entre associação e causalidade."
4. **NB e EM:** "Implemente MLE, MAP Beta(2,2), Naive Bayes do zero e EM Bernoulli com dois perfis. Ajuste somente no treino, mostre a log-verossimilhança e compare NB com e sem perfil, mesmo que o resultado piore."
5. **Fuzzy:** "Receba a probabilidade da Etapa 5 e o suporte amostral em um Mamdani com triângulos e 3–5 regras. Compare com limiar 0,5 e explique a urgência sem tratá-la como probabilidade."
6. **Revisão e artigo:** "Confira o repositório contra o enunciado, separe pendências importantes de melhorias opcionais e produza um artigo LaTeX com resultados verificados, limitações, cálculos e apêndice de uso de IA."

O código e os resultados, e não a resposta do chatbot, são a evidência do trabalho. As verificações descritas no artigo incluem contagens, equivalência numérica entre implementações e avaliação fora do treino. A equipe deve compreender os métodos e revisar o texto antes da entrega.